

Hoja de Trabajo 1: Redes Neuronales

Deep Learning y Sistemas Inteligentes - CC3092

José Antonio Mérida Castejón

10 de julio de 2026

Task 1

Responda de forma clara:

1. *Explique con sus propias palabras por que una red neuronal compuesta únicamente de transformaciones lineales, sin funciones de activación no lineales, tiene exactamente la misma capacidad expresiva que un modelo lineal de una sola capa. Su explicación debe incluir el argumento algebraico central.*

En términos resumidos, la composición de capas lineales resulta en otra capa lineal. Esto quiere decir que no importa cuantas veces multipliquemos la entrada por una matriz de pesos, el resultado seguirá siendo el mismo que multiplicarlo por una única matriz. Además, sin importar cuantos vectores de *bias* sumemos seguiremos obteniendo otro vector de *bias*. Para una demostración más formal consideremos lo siguiente:

Una capa lineal aplica a la entrada $x \in \mathbb{R}^n$ una transformación de la forma

$$f_1(x) = W_1x + b_1,$$

donde $W_1 \in \mathbb{R}^{k \times n}$ es la matriz de pesos y $b_1 \in \mathbb{R}^k$ el *bias*, de modo que f_1 va de $\mathbb{R}^n \rightarrow \mathbb{R}^k$.

Ahora, consideremos una segunda capa $f_2 : \mathbb{R}^k \rightarrow \mathbb{R}^m$, con $W_2 \in \mathbb{R}^{m \times k}$ y $b_2 \in \mathbb{R}^m$:

$$f_2(y) = W_2y + b_2.$$

Al componer ambas sin una función de activación de por medio:

$$f_2(f_1(x)) = W_2(W_1x + b_1) + b_2 = (W_2W_1)x + (W_2b_1 + b_2).$$

El producto W_2W_1 es de nuevo una matriz $W' = W_2W_1 \in \mathbb{R}^{m \times n}$. De igual forma, b_1 es multiplicado por W_2 , que lo lleva de $\mathbb{R}^k$ a $\mathbb{R}^m$, y al sumarle b_2 obtenemos otro vector $W_2b_1 + b_2 = b' \in \mathbb{R}^m$. Por lo tanto:

$$f_2(f_1(x)) = W'x + b',$$

que tiene la misma forma que una única capa $f' : \mathbb{R}^n \rightarrow \mathbb{R}^m$. Repitiendo el argumento, cualquier número de capas colapsa en una sola $W'x + b'$, por lo que la red tiene la misma capacidad expresiva que un modelo lineal de una sola capa.

2. Considere una neurona con dos entradas $x_1 = 3$ y $x_2 = -2$, pesos $w_1 = 0,4$ y $w_2 = 0,6$, y sesgo $b = -0,1$. Calcule la preactivación z y la activación $a = \sigma(z)$. Interprete el resultado, ¿Qué le indica este valor sobre la predicción del modelo?

$$z = w_1x_1 + w_2x_2 + b = (0,4)(3) + (0,6)(-2) + (-0,1) = -0,1.$$

$$a = \sigma(z) = \frac{1}{1 + e^{-z}} = \frac{1}{1 + e^{0,1}} \approx 0,4750.$$

La activación $a \approx 0,475$ se interpreta como la probabilidad estimada de que la entrada pertenezca a la clase positiva, es decir, $P(y = 1 \mid x) \approx 0,475$. Como este valor está apenas por debajo de 0,5, el modelo predice la clase negativa (*no*), pero por un margen muy pequeño.