

Hoja de Trabajo 1: Redes Neuronales

Deep Learning y Sistemas Inteligentes - CC3092

José Antonio Mérida Castejón

12 de julio de 2026

Task 1

Responda de forma clara:

- a. *Explique con sus propias palabras por que una red neuronal compuesta únicamente de transformaciones lineales, sin funciones de activación no lineales, tiene exactamente la misma capacidad expresiva que un modelo lineal de una sola capa. Su explicación debe incluir el argumento algebraico central.*

En términos resumidos, la composición de capas lineales resulta en otra capa lineal. Esto quiere decir que no importa cuantas veces multipliquemos la entrada por una matriz de pesos, el resultado seguirá siendo el mismo que multiplicarlo por una única matriz. Además, sin importar cuantos vectores de *bias* sumemos seguiremos obteniendo otro vector de *bias*. Para una demostración más formal consideremos lo siguiente:

Una capa lineal aplica a la entrada $x \in \mathbb{R}^n$ una transformación de la forma

$$f_1(x) = W_1x + b_1,$$

donde $W_1 \in \mathbb{R}^{k \times n}$ es la matriz de pesos y $b_1 \in \mathbb{R}^k$ el *bias*, de modo que f_1 va de $\mathbb{R}^n \rightarrow \mathbb{R}^k$.

Ahora, consideremos una segunda capa $f_2 : \mathbb{R}^k \rightarrow \mathbb{R}^m$, con $W_2 \in \mathbb{R}^{m \times k}$ y $b_2 \in \mathbb{R}^m$:

$$f_2(y) = W_2y + b_2.$$

Al componer ambas sin una función de activación de por medio:

$$f_2(f_1(x)) = W_2(W_1x + b_1) + b_2 = (W_2W_1)x + (W_2b_1 + b_2).$$

El producto W_2W_1 es de nuevo una matriz $W' = W_2W_1 \in \mathbb{R}^{m \times n}$. De igual forma, b_1 es multiplicado por W_2 , que lo lleva de $\mathbb{R}^k$ a $\mathbb{R}^m$, y al sumarle b_2 obtenemos otro vector $W_2b_1 + b_2 = b' \in \mathbb{R}^m$. Por lo tanto:

$$f_2(f_1(x)) = W'x + b',$$

que tiene la misma forma que una única capa $f' : \mathbb{R}^n \rightarrow \mathbb{R}^m$. Repitiendo el argumento, cualquier número de capas colapsa en una sola $W'x + b'$, por lo que la red tiene la misma capacidad expresiva que un modelo lineal de una sola capa.

- b. Considere una neurona con dos entradas $x_1 = 3$ y $x_2 = -2$, pesos $w_1 = 0,4$ y $w_2 = 0,6$, y sesgo $b = -0,1$. Calcule la preactivación z y la activación $a = \sigma(z)$. Interprete el resultado, ¿Qué le indica este valor sobre la predicción del modelo?

$$z = w_1x_1 + w_2x_2 + b = (0,4)(3) + (0,6)(-2) + (-0,1) = -0,1.$$

$$a = \sigma(z) = \frac{1}{1 + e^{-z}} = \frac{1}{1 + e^{0,1}} \approx 0,4750.$$

La activación $a \approx 0,475$ se interpreta como la probabilidad estimada de que la entrada pertenezca a la clase positiva, es decir, $P(y = 1 | x) \approx 0,475$. Como este valor está apenas por debajo de 0,5, el modelo predice la clase negativa (*no*), pero por un margen muy pequeño. Esto nos indica que es un *sample* que realmente no es muy parecido a alguna de las clases del conjunto de entrenamiento y el modelo no “está muy seguro” de la predicción realizada.

Task 2

Responda de forma clara y deje evidencia de sus cálculos:

- a. Muestre paso a paso como se obtiene la fórmula de entropía cruzada binaria a partir del principio de máxima verosimilitud bajo una distribución de Bernoulli. Indique claramente en que paso se aplica el logaritmo y por qué eso es válido.

Para una clasificación binaria, se cuenta con labels $y \in \{0, 1\}$ y predicciones probabilísticas $\hat{y} \in (0, 1)$. La distribución de Bernoulli nos indica lo siguiente:

$$P(y | \hat{y}) = \hat{y}^y (1 - \hat{y})^{1-y}$$

Es decir, la probabilidad es $\hat{y}$ si $y = 1$ y $1 - \hat{y}$ si $y = 0$. Para un conjunto de N muestras independientes, la función de *likelihood* (L) se define como el producto de probabilidades de cada observación individual dado que para dos eventos independientes $P(A \cap B) = P(A) \times P(B)$:

$$L = \prod_{i=1}^N P(y_i | \hat{y}_i) = \prod_{i=1}^N \hat{y}_i^{y_i} (1 - \hat{y}_i)^{1-y_i}$$

Entonces, el principio de *maximum likelihood* busca maximizar esta función [1].

- b. Para un mismo ejemplo de entrenamiento con etiqueta $y = 0$, calcule la pérdida $\mathcal{L}$ cuando el modelo predice $\hat{y} = 0,1$, $\hat{y} = 0,5$ y $\hat{y} = 0,9$. ¿Qué observa sobre el comportamiento de la pérdida a medida que la predicción se aleja de la etiqueta correcta? ¿Es ese comportamiento deseable en un sistema de clasificación?
- c. Un ingeniero propone usar error cuadrático medio en lugar de entropía cruzada para entrenar la regresión logística. Formule un argumento técnico concreto contra esa decisión.

Task 3

- a. Dado el grafo de cómputo de la regresión logística:

$$x \rightarrow z = w^T x + b \rightarrow \hat{y} = \sigma(z) \rightarrow \mathcal{L}(\hat{y}, y)$$

Derive $\frac{\partial \mathcal{L}}{\partial w}$ paso a paso usando la regla de la cadena. Identifique en que paso aparece el resultado $\hat{y} - y$ y explique por que ese resultado es matemáticamente conveniente para el entrenamiento.

- b. *Utilizando el script de Python proporcionado como recurso complementario de la semana, ejecute el entrenamiento y reporte: el valor del costo J en la época 0, en la época 250 y en la época final. Grafique la curva de costo en función de las épocas. Incluya la gráfica como imagen en su entrega e interprete brevemente lo que muestra sobre la convergencia del modelo.*

Referencias

- [1] Daniel Godoy. *Understanding binary cross-entropy / log loss: a visual explanation*. Towards Data Science. Accessed: 2026-07-12. 2018. URL: <https://towardsdatascience.com/understanding-binary-cross-entropy-log-loss-a-visual-explanation-a3ac6025181a/>.