

Detección de lavado de dinero en remesas con aprendizaje en dos etapas

Deep Learning y Sistemas Inteligentes - CC3092 Proyecto 2: reporte ejecutivo

José Antonio Mérida Castejón

2 de octubre de 2026

Resumen ejecutivo

Qué se construyó. Un sistema que ordena a los remitentes de una remesadora según qué tan probable es que estén lavando dinero, y que explica cada alerta señalando las transacciones concretas que la provocaron. La Etapa A aprende, sin etiquetas, cómo se ve el comportamiento normal; la Etapa B aprende de casos etiquetados a distinguir el lavado, partiendo de lo que aprendió la Etapa A.

Con qué datos. IBM AML (HI-Small), un dataset sintético de 5,078,345 transacciones donde solo 0.10 % (1 de cada 980) es lavado. No hay datos reales etiquetados de remesas, así que las cifras describen el simulador y no una remesadora real.

Qué se encontró.

- Si el equipo de cumplimiento revisa el 5 % de los remitentes que el sistema considera más riesgosos (unos 2,575 de 51,637), encuentra **78 % de los lavadores** del conjunto de prueba. Alrededor de **15 % de esas alertas son reales**, contra 1–5 % en sistemas por reglas.
- Aun así, **85 % de las alertas siguen siendo falsos positivos**. Reduce la carga de revisión, no la elimina.
- **Resultado negativo:** el sistema de dos etapas *no supera* a un clasificador entrenado desde cero sin la Etapa A, solo lo iguala (PR-AUC de 0.572 contra 0.582, diferencia dentro del ruido). El efecto de preentrenar es inconsistente entre arquitecturas.
- La explicación funciona: en 67 % de los casos detectados, la transacción a la que el modelo más atención presta es de lavado (elegir al azar acierta 23 %).

Qué falta. Datos reales etiquetados, calibración, cubrir a los remitentes de una sola transacción (31 %) y más de una corrida por modelo (sección 6).

1. El problema de negocio y su contexto regulatorio

Guatemala recibe más de USD 20 mil millones anuales en remesas, cerca del 19% del PIB, y el corredor hacia Estados Unidos es de los más importantes del mundo. Ese volumen facilita el fraccionamiento de montos y obliga a remesadoras y bancos a vigilar sus operaciones.

En Guatemala, el marco vigente es el Decreto 15-2026, Ley Integral para la Prevención y Represión del Lavado de Dinero u Otros Activos y del Financiamiento del Terrorismo [1]. Entró en vigor el 17 de septiembre de 2026 y unifica los Decretos 67-2001 y 58-2005, que deroga (el enunciado todavía cita el primero). La Superintendencia de Bancos supervisa el régimen a través de la Intendencia de Verificación Especial (IVE). Las personas obligadas, entre ellas quienes realizan transferencias de fondos o valores, deben administrar sus riesgos por cliente, geografía, canal y producto, monitorear sus operaciones y reportar las sospechosas a la IVE. El reglamento operativo estaba pendiente al redactar este reporte.

A nivel regional e internacional, las Recomendaciones del GAFI piden regular los servicios de transferencia de dinero o valores (Recomendación 14), controlar las transferencias electrónicas (16) y reportar transacciones sospechosas (20) [2]. En Estados Unidos, las empresas de servicios monetarios se registran ante FinCEN y reportan actividad sospechosa a partir de USD 2,000 [3].

Qué problema resuelve el sistema. Los sistemas por reglas tienen 95–99% de falsos positivos, según el enunciado, y una alerta sin explicación no sirve en un entorno regulado: el analista necesita saber qué transacciones la dispararon. Por eso el sistema ordena a los remitentes por riesgo (el equipo revisa desde arriba hasta donde alcance su capacidad) y resalta las transacciones responsables.

2. Datos y construcción de secuencias

Se usó IBM AML (HI-Small) [4] y no PaySim porque simula bancos, personas y empresas con lavado inyectado en tipologías conocidas y remitentes con historia repetida, que es lo que necesita un modelo de secuencias. En total hay 496,999 remitentes, de los que 3,376 (0.68%) lavan en algún momento.

El análisis exploratorio, antes de modelar, produjo hallazgos que se volvieron decisiones:

- **El tiempo absoluto es un artefacto del simulador.** La actividad normal se detiene tras el 10 de septiembre, pero el simulador sigue generando lavado (esa cola tiene 12.7% del total), y los volúmenes por día y hora saltan entre niveles fijos. El modelo solo ve el tiempo desde la transacción anterior del remitente, sin fecha ni hora.
- **Un formato de pago concentra el lavado.** ACH tiene 87% de las transacciones de lavado; Wire y Reinvestment no tienen ninguna. No se eliminaron (son comportamiento real), pero en entrenamiento se submuestran los remitentes que solo usan esos formatos: son negativos seguros que enseñan una regla fácil.
- **El monto solo no separa las clases.** Los de lavado son mayores (mediana de USD 5,879 contra 891) pero se traslapan mucho, y abarcan 14 órdenes de magnitud; se usa el logaritmo del monto y el monto relativo al típico del remitente.
- **Hay ocho tipologías de lavado** (fan-in, fan-out, ciclos, entre otras), pero solo 62% de las transacciones de lavado pertenece a una. Las tipologías no se usan como features (serían etiquetas disfrazadas), solo para evaluar y explicar.

Decisión	Elección	Justificación
Features (11 por transacción)	Monto (log y relativo), tiempo desde la anterior, si es el primero, auto-transferencia, mismo banco, cambio de moneda, receptor nuevo, remitentes distintos que ha recibido el receptor, formato y moneda de pago	Todos relativos al remitente; ninguno es fecha ni hora. El conteo de remitentes del receptor da contexto de red (fan-in) y se calcula sin mirar el futuro
Normalización	Logaritmo de montos en USD; z-score con estadísticas solo de entrenamiento	Montos de 14 órdenes de magnitud; sin fuga entre splits
Largo mínimo	2 transacciones	Una sola no forma una secuencia. Bajar de 3 a 2 recupera cerca de 500 remitentes positivos (+18 %); los de una sola transacción (31 %) quedan fuera
Largo máximo	Ventanas de 32 transacciones, paso de 16, a lo más 12 por remitente	Cubre la historia de casi todos y los intentos de lavado (5 a 14 transacciones); el solape evita cortar un patrón por el borde; el tope evita que una cuenta muy activa domine
Desbalance	Submuestreo de Wire/Reinvestment en entrenamiento; en la Etapa B, 40 negativos por positivo y focal loss; métricas basadas en PR	Solo 0.10 % de las transacciones y 0.93 % de las ventanas de entrenamiento son positivas; validación y prueba conservan la distribución real
División	70/15/15 por remitente, estratificada por lavado y por cola	Las ventanas solapadas de un remitente comparten transacciones; separarlas filtraría información

Cuadro 1: Decisiones de datos y su justificación. Cada ventana es positiva si contiene una transacción de lavado.

La Etapa B entrena con 208,600 remitentes (2,270 positivos); validación y prueba tienen 51,637 cada uno (486 positivos en prueba). El notebook verifica con pruebas automáticas que ningún remitente caiga en dos splits y que las etiquetas sean consistentes, y muestra la distribución de largos (mediana de 2 transacciones por remitente) y ejemplos de secuencias normales y sospechosas. Estas últimas no se distinguen a simple vista: cada una tiene un solo pago de lavado entre transacciones de aspecto normal, y la señal está en la combinación de monto, tiempo, receptor y formato, lo que justifica un modelo de secuencias.

3. Diseño del sistema

3.1. Etapa A: aprender lo normal

Idea. Hay muy pocos positivos y el lavado cambia de forma, así que en lugar de definir qué es sospechoso se aprende qué es normal, que es lo abundante. Un autoencoder (Lab-03) comprime cada ventana a 32 números y trata de reconstruirla; una ventana que no se parece a nada de lo visto se reconstruye mal, y ese error es el puntaje de anomalía. El decoder solo recibe esos 32 números y la posición que debe llenar, nunca la ventana original: si la viera, la copiaría entera, anomalías incluidas, y no habría nada que aprender. Se entrena solo con ventanas de remitentes




Figura 1: Las dos etapas. La Etapa A se entrena solo con remitentes normales y no usa etiquetas; la Etapa B usa etiquetas y puede partir del encoder de la Etapa A.

que nunca lavaron.

Qué arquitecturas se probaron y por qué. Se compararon tres encoders con la misma pérdida y receta de entrenamiento, para que la diferencia sea solo la arquitectura. Un MLP sobre la ventana aplanada, que no modela orden, es el piso: si los demás no lo superan, la secuencia no aporta. Un LSTM bidireccional [5] lee las transacciones en orden con una memoria, lo que importa cuando lo relevante es qué pasó antes (Lab-02). Un Transformer [6] deja que cada transacción mire a todas las demás (Lab-04, Proyecto 1), útil para patrones como montos repetidos, y se usa en detección de anomalías en series de tiempo [7]. Los dos terminan en un attention pooling que maneja largos variables y da un peso por transacción, que luego sirve de mapa de calor.

Puntaje y umbral. El error crece con el largo de la ventana, así que un puntaje crudo mediría cuánta actividad tiene el remitente y no qué tan raro es. Validación eligió, entre tres puntajes y dos agregaciones, el error de las 3 peores transacciones normalizado por largo, con el máximo sobre ventanas. El umbral de alerta es el puntaje de validación que deja alertado al 5 % de los remitentes, la capacidad real de revisión del equipo; se descartó el de mejor F1, que alertaba apenas al 0.5 %.

3.2. Etapa B: clasificador y transfer learning

La Etapa B es un clasificador: un encoder, un attention pooling nuevo y un MLP que da la probabilidad de lavado de cada ventana. La probabilidad de un remitente es la de su ventana más sospechosa, porque un remitente es positivo si alguna ventana contiene lavado y un promedio diluiría una ventana mala entre muchas normales.

Estrategia de transfer learning (Semana 9, Lab-06). Hay solo 2,270 remitentes positivos contra 206 mil normales, y el encoder de la Etapa A ya vio a los normales; la hipótesis es que esa representación ayuda al clasificador. Se probó con LSTM y con Transformer, para ver si la conclusión depende de la arquitectura (el MLP no produce un vector por transacción), con tres variantes que responden preguntas distintas:

- **Desde cero:** pesos aleatorios, solo con etiquetas. Es el baseline: si no se le gana, el preentrenamiento no aporta.
- **Congelado:** se usa el encoder de la Etapa A sin modificarlo y se entrena solo el pooling y la cabeza. Mide el valor puro de la representación.
- **Ajustado:** se parte del encoder de la Etapa A y se entrena todo, con el encoder a un décimo del learning rate y una primera época solo con la cabeza, para que gradientes ruidosos no dañen lo aprendido. Prueba si adaptarla mejora lo anterior.

Pérdida (Lab-05). Con 0.93 % de ventanas positivas, cada época usa todas ellas y 40 negativos por positivo. Se compararon la focal loss [8], que le quita peso a lo que ya se acierta, y la entropía cruzada ponderada (positivos $\times 40$), ambas respuestas estándar al desbalance. Ganó la focal en validación y se usó en los seis modelos.

Combinación de señales. La predicción final es $w \cdot \text{pct}(B) + (1 - w) \cdot \text{pct}(A)$, con pct el percentil de cada puntaje y w elegido en validación. Prueba si el puntaje de anomalía agrega algo; con $w = 1$ la Etapa A no aporta.

3.3. Métricas

Con 0.1 % de positivos, la exactitud no sirve (alertar nunca da 99.9 %). La métrica de selección es el PR-AUC por remitente, que mide la calidad de todo el ranking (un ranking aleatorio da 0.009). Para el negocio se reportan el **recall al 5 %** (qué fracción de los lavadores encuentra el equipo si revisa el 5 % más riesgoso) y la **precisión** (de las alertas, cuántas son reales), tanto en las 100 alertas más altas como en el 5 % completo. Todo se evalúa por remitente, que es la unidad que recibe una alerta, con intervalos bootstrap del 95 %.

4. Resultados del experimento de ablación

El experimento obligatorio compara el sistema de dos etapas contra un clasificador entrenado desde cero. La primera tabla muestra qué logra la Etapa A sola.

Etapa A (sin etiquetas)	PR-AUC prueba	Recall @5 %	Precisión @5 %
MLP (baseline)	0.243	0.47	0.09
LSTM	0.158	0.43	0.08
Transformer	0.157	0.46	0.09

Cuadro 2: Etapa A sola, en el conjunto de prueba. Un ranking aleatorio da 0.009 de PR-AUC.

Los tres autoencoders rankean entre 17 y 26 veces mejor que el azar y encuentran 43–47 % de los lavadores al alertar al 5 %, pero sin etiquetas el puntaje solo mide qué tan inusual es una ventana, no si es lavado, y casi no detecta el lavado sin tipología (14 %). El MLP, el más simple, ganó, lo que no se esperaba; no se verificó por qué.

Etapa B	PR-AUC val.	PR-AUC prueba [IC 95 %]	Recall @5 %	P@100	P@5 %
LSTM desde cero	0.612	0.582 [0.542, 0.625]	0.79	1.00	0.15
LSTM congelado	0.354	0.321 [0.283, 0.360]	0.54	0.87	0.10
LSTM ajustado	0.515	0.497 [0.457, 0.539]	0.70	1.00	0.13
Transformer desde cero	0.594	0.558 [0.517, 0.598]	0.79	1.00	0.15
Transformer congelado	0.549	0.504 [0.460, 0.555]	0.73	0.96	0.14
Transformer ajustado (final)	0.600	0.572 [0.531, 0.614]	0.78	1.00	0.15

Cuadro 3: Etapa B: seis modelos con el mismo loss, muestreo y early stopping. P@ k es la precisión de las k alertas más altas o del 5 % alertado.

El salto grande es pasar a supervisado: de 0.16–0.24 a 0.3–0.6 de PR-AUC. El efecto de preentrenar, en cambio, es inconsistente. Según un bootstrap pareado sobre PR-AUC, con el Transformer el ajuste fino queda ligeramente por encima de entrenar desde cero (+0.014, IC 95 % [−0.002, +0.030],




Figura 2: PR-AUC en prueba por modelo. Gris: Etapa A sola. Azul: Etapa B.

dentro del ruido) y congelar pierde (-0.054); con el LSTM, ajustar es claramente peor (-0.085 , $[-0.108, -0.063]$) y congelar mucho peor (-0.261). La mezcla con la Etapa A tampoco ayuda: validación eligió $w = 1$ en cinco de los seis modelos. Si preentrenar aportara algo general, el signo sería el mismo en las dos arquitecturas; lo más probable es que no haya un efecto real y que las diferencias vengan de ruido (una sola semilla, y resultados que cambian un poco entre corridas) y de cómo se optimiza cada encoder. Una explicación posible, no verificada, es que reconstruir lo normal no obliga al encoder a representar lo que distingue al lavado [9].

El modelo final es el **Transformer ajustado**. Empata en la práctica con el LSTM desde cero (PR-AUC de prueba 0.572 contra 0.582, diferencia -0.011 con IC $[-0.027, +0.007]$; recall al 5 % de 0.78 contra 0.79; el LSTM tiene un PR-AUC de validación apenas mayor, 0.612 contra 0.600), y entre las dos arquitecturas desde cero el LSTM supera al Transformer por 0.025 ($[+0.008, +0.042]$), coherente con que modelos simples compitan con los Transformers [10]. Se eligió porque es el mejor sistema que usa la Etapa A, que es lo que pide el proyecto, y porque su atención sí señala el lavado (sección siguiente); el LSTM desde cero queda como baseline. La conclusión honesta es que la Etapa A no hizo mejor al clasificador: el sistema de dos etapas lo iguala.

5. Interpretabilidad y análisis de casos

El modelo final tiene un attention pooling que da un peso por transacción, pero los pesos de atención no son por sí mismos una explicación fiel [11]. Como el dataset marca las transacciones de lavado, se puede medir si la atención cae sobre ellas y compararla con el error de reconstrucción por transacción de la Etapa A. En los 381 remitentes positivos detectados cuya mejor ventana contiene lavado, la transacción con más atención es de lavado el 67 % de las veces (elegir al azar: 23 %), y la de mayor error de reconstrucción de la Etapa A lo es el 72 %. Ambas señales sirven como explicación, y la segunda es independiente de la primera.

Tipología	Positivos	Detectados	Recall
FAN-OUT	3	3	1.00
SCATTER-GATHER	43	41	0.95
CYCLE	35	33	0.94
RANDOM	29	27	0.93
STACK	58	55	0.95
FAN-IN	51	46	0.90
BIPARTITE	30	23	0.77
GATHER-SCATTER	42	33	0.79
Sin tipología	195	120	0.62
Total	486	381	0.78

Cuadro 4: Detección por tipología del sistema final, con 5 % de remitentes alertados, en prueba.

Las tipologías nombradas se detectan bien (77–100 %, Cuadro 4); lo que se escapa es sobre todo el lavado sin tipología, el 40 % de los positivos, que la Etapa A sola casi no ve (14 %). Los positivos de la cola se detectan más que el resto (93 % contra 76 %), a pesar de que el modelo no ve tiempo absoluto: es una señal a vigilar de un posible artefacto del simulador.

Se analizaron cinco casos de prueba, elegidos automáticamente: los tres verdaderos positivos mejor rankeados, el falso positivo mejor rankeado y el positivo con tipología conocida peor rankeado. Cada uno tiene mapa de calor y explicación en lenguaje natural, el mismo texto del demo web.

- **Verdadero positivo 1 (fan-in).** 5 transacciones; solo la última (USD 18,515 por ACH) es de lavado y concentra 96 % de la atención: un pago a un receptor nuevo que ya había recibido de 17 remitentes distintos, hecho al mismo tiempo que el anterior. Es el patrón de fan-in: muchos remitentes convergen en un receptor.
- **Verdadero positivo 2 (fan-in).** El mismo patrón: la última transacción (USD 19,031, a un receptor que ya había recibido de 12 remitentes) recibe 94 % de la atención.
- **Verdadero positivo 3 (fan-in).** 32 transacciones; solo la última (USD 8,334 a un receptor nuevo) es de lavado y recibe 98 % de la atención, aunque solo 22 % de la ventana es ACH.
- **Falso positivo.** Un remitente legítimo con 6 pagos por ACH, dos de exactamente USD 2,318 sin separación en el tiempo y uno de USD 0. Parece fraccionamiento de montos, y el modelo no puede saber que es legítimo. La explicación le muestra al analista por qué saltó.
- **Falso negativo (bipartite).** La transacción de lavado es la #2 (USD 8,809 a un receptor nuevo) y la atención sí la encuentra (58 %), pero el clasificador dejó al remitente en el percentil 82, fuera del 5 % alertado. La Etapa A lo ubicó en el percentil 99 de anomalía, pero con $w = 1$ esa señal no entra a la decisión.

6. Limitaciones y camino a producción

Limitaciones.

- Los datos son sintéticos y tienen artefactos del simulador; los resultados no se pueden extrapolar a remesas reales ni a su tasa de lavado.
- La vista por remitente ve un solo lado de un fenómeno de red: detecta 77–100 % de las tipologías nombradas, pero 62 % del lavado sin tipología. Un modelo de grafos podría ver mejor esos casos. Los remitentes de una sola transacción (31 %) quedan fuera del alcance.
- El preentrenamiento no mejoró de forma consistente. Habría que probar un objetivo más cercano a la tarea, o usar los errores de la Etapa A como feature.
- Hay una sola semilla por modelo y los resultados cambian un poco entre corridas: no se puede separar un efecto real del preentrenamiento de ruido de optimización.

Para llevarlo a producción en una remesadora.

- **Datos reales etiquetados**, como los reportes de operaciones sospechosas; son incompletos y tardan en llegar.
- **Calibración y umbrales**. Las probabilidades no están calibradas por el muestreo de negativos; el umbral debe fijarse con la capacidad real de revisión y el reglamento del Decreto 15-2026.
- **Monitoreo y reentrenamiento**. Vigilar el volumen de alertas, la deriva de los datos y la tasa de aciertos, y reentrenar periódicamente.
- **Revisión humana y gobierno del modelo**. Cada alerta pasa por un analista con la explicación a la vista y queda registrada para auditoría; el modelo se documenta y se valida de forma independiente.

7. Uso de IA generativa

Se usó Claude (Anthropic), a través de Claude Code, para reorganizar el código del notebook de las etapas A y B, documentar el notebook, verificar referencias y ley vigente, construir el demo web y redactar el borrador de este reporte a partir de los resultados. Las decisiones de diseño fueron del grupo: usar un autoencoder encoder-decoder en la Etapa A; agregar un MLP como baseline; comparar LSTM y Transformer en ambas etapas en lugar de fijar una arquitectura; y fijar el umbral en el 5 % de remitentes alertados como base del análisis de negocio. La IA propuso la hipótesis sobre por qué el preentrenamiento no ayudó, marcada en el texto como no verificada.

Referencias

- [1] Congreso de la República de Guatemala. *Decreto 15-2026, Ley Integral para la Prevención y Represión del Lavado de Dinero u Otros Activos y del Financiamiento del Terrorismo*. Aprobado el 2 de junio de 2026; publicado en el Diario de Centro América el 17 de junio de 2026. 2026. URL: https://www.congreso.gob.gt/noticias_congreso/16190/2026/4.
- [2] Financial Action Task Force. *International Standards on Combating Money Laundering and the Financing of Terrorism and Proliferation: The FATF Recommendations*. Recomendaciones 14, 16 y 20 (versión actualizada). 2012. URL: <https://www.fatf-gafi.org/en/publications/Fatfrecommendations/Fatf-recommendations.html>.

- [3] Financial Crimes Enforcement Network. *31 CFR Part 1022: Rules for Money Services Businesses*. Electronic Code of Federal Regulations. URL: <https://www.ecfr.gov/current/title-31/subtitle-B/chapter-X/part-1022>.
- [4] Erik Altman et al. «Realistic Synthetic Financial Transactions for Anti-Money Laundering Models». En: *Advances in Neural Information Processing Systems 36 (NeurIPS), Datasets and Benchmarks Track*. 2023. URL: https://proceedings.neurips.cc/paper_files/paper/2023/hash/5f38404edff6f3f642d6fa5892479c42-Abstract-Datasets_and_Benchmarks.html.
- [5] Sepp Hochreiter y Jürgen Schmidhuber. «Long Short-Term Memory». En: *Neural Computation* 9.8 (1997), págs. 1735-1780.
- [6] Ashish Vaswani et al. «Attention Is All You Need». En: *Advances in Neural Information Processing Systems 30 (NeurIPS)*. 2017.
- [7] Jiehui Xu et al. «Anomaly Transformer: Time Series Anomaly Detection with Association Discrepancy». En: *International Conference on Learning Representations (ICLR)*. 2022.
- [8] Tsung-Yi Lin et al. «Focal Loss for Dense Object Detection». En: *IEEE International Conference on Computer Vision (ICCV)*. 2017, págs. 2980-2988.
- [9] Suchin Gururangan et al. «Don't Stop Pretraining: Adapt Language Models to Domains and Tasks». En: *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)*. 2020, págs. 8342-8360. URL: <https://aclanthology.org/2020.acl-main.740/>.
- [10] Ailing Zeng et al. «Are Transformers Effective for Time Series Forecasting?» En: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 37. 9. 2023, págs. 11121-11128.
- [11] Sarthak Jain y Byron C. Wallace. «Attention is not Explanation». En: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL)*. 2019, págs. 3543-3556.